

LAPORAN *MACHINE LEARNING*

Topik : Penerapan Face Recognition pada Sistem Human Resource Information System (HRIS) Labersa Hotel and Convention Center



11423001	:	Samuel Leonardo Nainggolan
11423021	:	Andika Parlinggoman Tampubolon
11423049	:	Yosia Yehezkiel Gurning
11423062	:	Monica Romauly Manik
11423063	:	Joy Ria Sihombing

**PROGRAM STUDI SARJANA TERAPAN
TEKNOLOGI REKAYASA PERANGKAT LUNAK
FAKULTAS VOKASI
INSTITUT TEKNOLOGI DEL
2026**

Daftar Isi

LAPORAN MACHINE LEARNING.....	1
BAB I.....	5
PENDAHULUAN.....	5
1.1 LATAR BELAKANG.....	5
1.2 RUMUSAN MASALAH.....	6
1.3 TUJUAN PROYEK.....	6
BAB II.....	7
TINJAUAN PUSTAKA.....	7
2.1 MACHINE LEARNING.....	7
2.2 COMPUTER VISION.....	7
2.2.1 Deteksi Wajah (Face Detection).....	7
2.2.2 Pengenalan Wajah (Face Recognition).....	8
2.3 Arsitektur FaceNet dan Konsep Transfer Learning.....	8
2.3.1 FaceNet.....	8
2.3.2 Transfer Learning Dua Tahap.....	9
2.4 Face Anti-Spoofing.....	9
2.5 Cosine Similarity untuk Face Verification.....	11
2.6 Validasi Keamanan Input.....	12
2.7 Sistem Informasi Sumber Daya Manusia (HRIS).....	14
2.8 Evaluasi Performa Model Biometrik.....	14
BAB III.....	16
ANALISIS DAN PERANCANGAN SISTEM.....	16
3.1 DATASET.....	16
3.1.1 Dataset Face Recognition/ Face Verification.....	16
3.1.2 Dataset Anti Spoofing.....	17
3.2 ARSITEKTUR SISTEM.....	18
3.3 Arsitektur Model LightClassifier.....	20
3.3 Perancangan Basis Data (Database Design).....	20
3.3.1 Skema Koleksi Face Profiles (face_embedding).....	21
3.5 Perancangan Antarmuka (User Interface Design).....	22
3.5.1 Antarmuka Terminal Siaga (Standby & Scanning Mode).....	22
3.5.2 Antarmuka Verifikasi Berhasil (Success Attendance View).....	23
3.5.3 Antarmuka Penolakan Keamanan & Atribut (Rejection & Fraud Warning View).....	23
BAB IV.....	24
IMPLEMENTASI.....	24
4.1 Preprocessing Data.....	24
4.1.1 Lokalisasi dan Ekstraksi Wajah (Face Cropping).....	25
4.1.2 Penyeragaman Dimensi (Resizing) dan Pembagian Data Terstratifikasi (Stratified Split).....	25
4.1.3 Pipeline Transformasi dan Augmentasi Citra.....	25
4.1.4 Standardisasi dan Normalisasi Nilai Piksel.....	26

4.1.5 Regulasi Batch Tingkat Lanjut (Advanced Regularization).....	27
4.2 Feature Engineering & Selection.....	27
4.2.1 Ekstraksi dan Rekayasa Embedding Wajah (Face Embedding Engineering).....	27
4.2.2 Pemilihan Fitur Otomatis Lewat Lapisan Konvolusi (Deep Feature Selection).....	28
4.2.3 Reduksi Dimensi Menggunakan Lapisan Global Average Pooling (GAP).....	28
4.2.4 Seleksi Fitur Adaptif Melalui Regularisasi L2 (Weight Decay).....	28
4.3 Data Splitting.....	29
4.3.1 Penerapan Stratified Sampling untuk Keseimbangan Kelas.....	29
4.3.2 Konfigurasi Pembagian dan Reproduksiabilitas Sistem.....	29
4.4 TRAINING MODEL.....	30
4.4.1 Implementasi Strategi Pre-Computing Embeddings.....	31
4.4.1 Mekanisme Simulasi Batch Lewat Gradient Accumulation dan bfloat16.....	31
4.4.2 Penjadwalan Dinamis OneCycleLR dan Regulasi Early Stopping.....	32
4.5 Hyperparameter Tuning.....	32
4.5.1 Komparasi Metodologi Grid Search dan Random Search.....	32
4.5.2 Tuning Parameter Regularisasi dan Augmentasi.....	33
4.5.3 Optimalisasi Penjadwalan Learning Rate dan Fungsi Kehilangan.....	33
4.6 Model Evaluation.....	34
4.6.1 Analisis Metrik Akurasi Tingkat Makro dan Sektorial.....	34
4.6.2 Evaluasi Keseimbangan Prediksi Lewat F1-Score Weighted dan Macro.....	35
4.6.3 Analisis Kurva Pelatihan dan Validasi Overfitting Gap.....	36
4.7 Implementasi Verifikasi Wajah.....	37
BAB V.....	39
HASIL DAN ANALISIS.....	39
5.1 LINGKUNGAN EKSPERIMEN DAN DATASET PENGUJIAN.....	39
5.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak.....	40
5.1.2 Karakteristik Dataset Uji.....	40
5.2 Hasil Pengujian Model Face Recognition.....	41
5.2.1 Analisis Metrik Kuantitatif.....	41
5.2.2 Analisis Kurva Pembelajaran (Learning Curves).....	42
5.2.3 Distribusi Akurasi per Kelas.....	43
5.3 Hasil Pengujian Model Anti-Spoofing.....	43
5.3.1 Analisis Weighted Ensemble.....	44
5.4 Analisis Kebingungan Model (Confusion Matrix Analysis).....	44
5.4.1 Matriks Kebingungan Multi-Kelas (Wajah).....	45
5.5 Integrasi Face Anti-Spoofing dan Face Recognition.....	45
BAB VI.....	46
KESIMPULAN.....	46
6.1 KESIMPULAN.....	46
6.2 SARAN.....	47
Daftar Pustaka.....	48

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri perhotelan dan pariwisata merupakan sektor yang menuntut efisiensi operasional tinggi dan pelayanan prima. Sebagai salah satu penyedia layanan akomodasi dan pertemuan terkemuka, Labersa Hotel and Convention Center memiliki mobilitas operasional yang sangat dinamis dengan melibatkan ratusan karyawan dari berbagai divisi, mulai dari *front office*, *housekeeping*, hingga manajemen. Dalam mengelola sumber daya manusia yang besar tersebut, peran *Human Resource Information System* (HRIS) menjadi sangat krusial untuk memastikan produktivitas, kedisiplinan, dan akurasi data kehadiran (presensi) karyawan.

Namun, sistem presensi konvensional yang saat ini umum digunakan seperti kartu RFID, PIN, maupun pemindai sidik jari (*fingerprint*) masih memiliki beberapa kelemahan signifikan. Sistem berbasis kartu dan PIN rentan terhadap tindakan kecurangan seperti penitipan absen (*buddy punching*). Di sisi lain, metode *fingerprint* sering kali mengalami kendala teknis pada proses pemindaian jika kondisi fisik jari karyawan basah, kotor, atau aus karena aktivitas operasional hotel. Selain itu, pada era pasca-pandemi, metode sentuh fisik seperti *fingerprint* juga dinilai kurang higienis untuk diterapkan di industri yang mengutamakan sanitasi tinggi seperti perhotelan.

Perkembangan teknologi *Artificial Intelligence* (AI), khususnya di bidang *Computer Vision*, menawarkan solusi modern melalui teknologi *Face Recognition* (Pengenalan Wajah). Dengan memanfaatkan algoritma *Deep Learning*, *Face Recognition* mampu mengidentifikasi dan memverifikasi identitas seseorang secara nirwas (tanpa sentuhan) melalui karakteristik wajah yang unik. Teknologi ini menawarkan tingkat akurasi yang tinggi, proses verifikasi yang cepat (dalam hitungan detik), serta eliminasi total terhadap risiko kecurangan absensi karena setiap data kehadiran terikat langsung pada biometrik wajah individu yang bersangkutan.

Integrasi teknologi *Face Recognition* ke dalam HRIS Labersa Hotel and Convention Center diproyeksikan dapat mentransformasi sistem manajemen SDM menjadi lebih aman, transparan, dan efisien. Sistem ini tidak hanya mencatat waktu kehadiran secara *real-time*, tetapi juga meminimalisir kesalahan input data manual dan mempercepat proses rekapitulasi performa karyawan oleh tim HRD.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah proyek ini adalah:

1. Bagaimana membangun sistem verifikasi wajah untuk memastikan karyawan yang melakukan absensi sesuai dengan identitas yang terdaftar?
2. Bagaimana menerapkan validasi keamanan seperti deteksi satu wajah, deteksi aksesoris, screen spoof detection, dan anti spoofing untuk mencegah manipulasi absensi?
3. Bagaimana performa model FaceNet/InceptionResnetV1 dalam menghasilkan embedding wajah serta efektivitas cosine similarity dalam proses verifikasi wajah?

1.3 Tujuan Proyek

Berikut merupakan tujuan proyek machine learning dengan topik penerapan face recognition pada sistem human resource information system labersa hotel dan convention centre :

1. Membangun sistem absensi otomatis berbasis Machine Learning dan Computer Vision.
2. Mengimplementasikan FaceNet/InceptionResnetV1 sebagai feature extractor untuk menghasilkan embedding wajah 512 dimensi.
3. Mengimplementasikan verifikasi wajah menggunakan cosine similarity antara embedding wajah baru dan embedding wajah yang tersimpan.
4. Menambahkan validasi keamanan berupa deteksi aksesoris dan face anti-spoofing.
5. Mengevaluasi performa model berdasarkan accuracy, weighted F1-score, macro F1-score, dan analisis threshold.

BAB II

TINJAUAN PUSTAKA

2.1 Machine Learning

Machine Learning (ML) merupakan cabang dari Kecerdasan Buatan (*Artificial Intelligence*) yang berfokus pada pengembangan sistem yang mampu belajar dari data, mengenali pola, dan mengambil keputusan dengan intervensi manusia yang minimal. Berbeda dengan pemrograman konvensional yang berbasis aturan (*rule-based*), ML mendasarkan kinerjanya pada pemodelan statistik dari data historis.

Dalam konteks sistem absensi HRIS Labersa Hotel, pendekatan yang diterapkan adalah *Supervised Learning* (Pembelajaran Terawasi). Algoritma dilatih menggunakan dataset yang telah diberi label (*labeled data*), di mana setiap sampel data input berupa citra wajah karyawan dipasangkan dengan label identitas yang valid. Secara matematis, proses pembelajaran ini bertujuan untuk menemukan fungsi pemetaan $f(x) = y$, di mana x adalah ekstraksi fitur wajah dan y adalah identitas karyawan. Model yang telah terlatih kemudian dievaluasi kemampuannya dalam menggeneralisasi data baru (*unseen data*) untuk memprediksi identitas wajah secara tepat waktu (*real-time*).

2.2 Computer Vision

Computer Vision adalah bidang ilmu yang mendasari komputer agar memiliki kemampuan indra penglihatan layaknya manusia, yaitu untuk mengekstrak, memproses, dan memahami informasi digital dari citra tunggal maupun sekuens video. Dalam sistem *Face Recognition* HRIS, alur kerja *Computer Vision* dibagi menjadi dua tahapan modular utama yang saling berkesinambungan:

2.2.1 Deteksi Wajah (Face Detection)

Deteksi wajah merupakan tahap inisiasi untuk menemukan lokasi, koordinat, dan batas daerah wajah (*bounding box*) di dalam sebuah citra tanpa memedulikan identitasnya. Proyek ini mengimplementasikan algoritma MTCNN (Multi-task Cascaded Convolutional Network). MTCNN bekerja melalui struktur *deep cascade* tiga tahap, yaitu:

1. P-Net (Proposal Network): Memindai citra pada berbagai skala (piramida citra) untuk menghasilkan kandidat kotak pembatas secara cepat.

2. R-Net (Refinement Network): Menyaring kandidat dari P-Net, menolak kotak yang salah (*false positives*), dan melakukan kalibrasi *bounding box*.
3. O-Net (Output Network): Tahap akhir yang menghasilkan koordinat wajah dengan akurasi tinggi serta mendeteksi lima titik *landmark* wajah utama (mata kiri, mata kanan, hidung, ujung mulut kiri, dan ujung mulut kanan).

2.2.2 Pengenalan Wajah (Face Recognition)

Setelah area wajah berhasil diekstrak oleh MTCNN, tahap berikutnya adalah *Face Recognition* untuk menentukan siapakah pemilik wajah tersebut. Proses ini melibatkan ekstraksi fitur intrinsik wajah yang kemudian dikonversi menjadi representasi vektor numerik. Vektor inilah yang nantinya akan dibandingkan dengan basis data karyawan hotel untuk mencari tingkat kemiripan tertinggi menggunakan metrik jarak seperti *Euclidean Distance* atau *Cosine Similarity*.

2.3 Arsitektur FaceNet dan Konsep Transfer Learning

2.3.1 FaceNet

FaceNet merupakan arsitektur *Deep Learning* untuk pengenalan wajah yang diperkenalkan oleh Schroff et al. (2015). Keunggulan utama FaceNet terletak pada kemampuannya memetakan citra wajah langsung ke dalam ruang vektor (*Euclidean space*) berdimensi tinggi (dalam kasus ini, 512 dimensi), di mana jarak antar-vektor merepresentasikan tingkat kemiripan wajah.

FaceNet dilatih menggunakan fungsi loss khusus yang disebut *Triplet Loss*. Fungsi ini secara simultan meminimalkan jarak antara wajah dari individu yang sama (*anchor* dan *positive*) dan memaksimalkan jarak antara wajah dari individu yang berbeda (*anchor* dan *negative*). Rumus matematika dari *Triplet Loss* dinyatakan sebagai berikut:

$$L = \sum_i^N \left[\left| f(x_i^a) - f(x_i^p) \right| - \left| f(x_i^a) - f(x_i^n) \right| + \alpha \right]$$

Di mana x^a adalah *anchor*, x^p adalah citra positif, x^n adalah citra negatif, dan α adalah nilai *margin* penalti.

2.3.2 Transfer Learning Dua Tahap

Membangun model *Deep Learning* dari nol memerlukan jutaan data gambar dan daya komputasi yang masif. Proyek ini mengatasi batasan tersebut dengan menerapkan teknik *Transfer Learning* menggunakan arsitektur InceptionResNetV1 yang telah dilatih sebelumnya (*pre-trained*) pada dataset skala besar VGGFace2.

Strategi adaptasi model dilakukan melalui dua tahapan struktural:

1. *Feature Extraction (Freeze Weights)*: Lapisan-lapisan awal dan menengah dari FaceNet yang berfungsi sebagai pengekstrak fitur global (seperti bentuk mata, hidung, dan rahang) dikunci perilakunya (*frozen*). Lapisan ini tidak akan mengalami perubahan bobot (*weights*) selama proses *training* baru.
2. *Classification Deployment (LightClassifier)*: Lapisan klasifikasi akhir bawaan FaceNet dilepas dan digantikan dengan lapisan baru yang lebih ringkas (*LightClassifier*), seperti *Dense Layer* berukuran kecil atau algoritma *Support Vector Machine* (SVM). Lapisan baru inilah yang dilatih secara khusus menggunakan dataset wajah internal karyawan Labersa Hotel untuk menghasilkan pemetaan identitas akhir.

2.4 Face Anti-Spoofing

Face Anti-Spoofing (FAS) merupakan teknik dalam bidang biometrik yang bertujuan untuk membedakan wajah asli (*live face*) dengan berbagai bentuk media pemalsuan (*spoof attack*) sebelum dilakukan proses pengenalan identitas. Penerapan Face Anti-Spoofing menjadi bagian penting dalam sistem absensi berbasis pengenalan wajah karena proses verifikasi identitas saja belum mampu menjamin bahwa wajah yang digunakan benar-benar berasal dari manusia yang hadir secara langsung di depan kamera.

Serangan terhadap sistem pengenalan wajah umumnya dilakukan menggunakan media dua dimensi maupun tiga dimensi, seperti foto cetak (*printed attack*), tampilan wajah melalui layar perangkat elektronik (*replay attack*), topeng (*mask attack*), maupun media tiruan lainnya. Apabila serangan tersebut tidak dapat dideteksi, maka sistem berpotensi menerima identitas yang sebenarnya tidak hadir secara fisik sehingga menurunkan tingkat keamanan sistem absensi.

Pada penelitian ini, mekanisme Face Anti-Spoofing diterapkan sebagai tahap awal sebelum proses ekstraksi fitur wajah menggunakan FaceNet. Setiap citra yang diterima terlebih dahulu dianalisis oleh model anti-spoofing untuk menentukan apakah wajah berasal dari objek hidup (*real*) atau media pemalsuan (*spoof*). Hanya citra yang diklasifikasikan sebagai **Real** yang akan diteruskan ke proses verifikasi identitas, sedangkan citra yang teridentifikasi sebagai **Spoof** akan langsung ditolak sehingga proses autentikasi dihentikan.

Berbeda dengan pendekatan yang hanya menggunakan satu model klasifikasi, sistem ini menerapkan pendekatan **weighted ensemble** yang mengombinasikan beberapa model Face Anti-Spoofing. Pendekatan ensemble dipilih karena mampu meningkatkan kemampuan generalisasi model terhadap berbagai variasi serangan spoofing. Setiap model melakukan inferensi secara independen terhadap citra masukan, kemudian menghasilkan probabilitas untuk kelas **Real** dan **Spoof**. Seluruh probabilitas tersebut selanjutnya digabungkan menggunakan bobot tertentu (*weighted voting*) sehingga menghasilkan keputusan akhir yang lebih stabil dibandingkan penggunaan model tunggal.

Model-model yang digunakan dalam penelitian ini terdiri atas MiniFASNet (SASF), FLRGB, ICM2O, IOM2C, dan CDCN++. Masing-masing model memiliki karakteristik yang berbeda dalam mempelajari tekstur permukaan wajah, distribusi warna, maupun karakteristik spasial yang muncul pada media pemalsuan. Kombinasi beberapa model tersebut memungkinkan sistem mendeteksi berbagai jenis serangan spoofing secara lebih robust dibandingkan hanya mengandalkan satu arsitektur jaringan saraf.

Keputusan akhir anti-spoofing diperoleh berdasarkan hasil agregasi seluruh model pada ensemble. Apabila hasil klasifikasi menunjukkan bahwa citra termasuk kategori **Spoof**, maka proses absensi langsung dihentikan. Sebaliknya, apabila hasil klasifikasi menunjukkan kategori **Real**, citra diteruskan ke tahap ekstraksi embedding menggunakan FaceNet untuk proses verifikasi identitas melalui perhitungan *cosine similarity*.

Dengan penerapan Face Anti-Spoofing berbasis weighted ensemble, sistem tidak hanya memverifikasi kecocokan identitas pengguna, tetapi juga memastikan bahwa identitas

tersebut berasal dari manusia yang benar-benar hadir di depan kamera. Pendekatan ini meningkatkan keamanan sistem HRIS terhadap berbagai bentuk penyalahgunaan absensi menggunakan foto, layar perangkat digital, maupun media tiruan lainnya.

2.5 Cosine Similarity untuk Face Verification

Face verification adalah proses untuk menentukan apakah dua wajah berasal dari orang yang sama atau tidak. Berbeda dengan face classification yang langsung memprediksi identitas atau nama seseorang, face verification membandingkan dua representasi wajah dalam bentuk vektor numerik. Pendekatan ini lebih sesuai untuk sistem absensi karena setiap karyawan cukup melakukan registrasi wajah satu kali, kemudian embedding wajahnya disimpan sebagai data acuan.

Pada proyek ini, wajah yang telah lolos tahap deteksi wajah, validasi keamanan, dan anti-spoofing akan diproses menggunakan FaceNet/InceptionResnetV1. Model FaceNet menghasilkan representasi wajah dalam bentuk embedding 512 dimensi. Embedding ini merupakan vektor numerik yang merepresentasikan karakteristik unik dari wajah seseorang.

Pada proses absensi, sistem akan menghasilkan embedding baru dari foto selfie pengguna. Embedding baru tersebut kemudian dibandingkan dengan embedding wajah yang sudah tersimpan di database. Perbandingan dilakukan menggunakan metode Cosine Similarity.

Cosine Similarity digunakan untuk mengukur tingkat kemiripan antara dua vektor berdasarkan arah atau sudut antar vektor. Rumus Cosine Similarity adalah sebagai berikut: **$\text{cosine_similarity} = (\mathbf{A} \cdot \mathbf{B}) / (\|\mathbf{A}\| \times \|\mathbf{B}\|)$**

Keterangan :

1. $\mathbf{A}$ = embedding wajah saat absensi
2. $\mathbf{B}$ = embedding wajah yang tersimpan saat registrasi
3. $\mathbf{A} \cdot \mathbf{B}$ = hasil dot product antara dua embedding
4. $\|\mathbf{A}\|$ dan $\|\mathbf{B}\|$ = panjang atau norma masing-masing embedding

Nilai cosine similarity menunjukkan tingkat kemiripan antara dua wajah. Semakin tinggi nilai similarity, maka semakin besar kemungkinan kedua embedding berasal dari orang yang sama. Pada proyek ini digunakan threshold: **SIMILARITY_THRESHOLD = 0.75**

Artinya, jika nilai similarity lebih besar atau sama dengan 0.75, maka wajah dianggap cocok dengan wajah yang tersimpan. Namun, keputusan akhir sistem tidak hanya bergantung pada similarity, karena wajah yang mirip belum tentu berasal dari input yang valid. Oleh karena itu, sistem juga mempertimbangkan skor anti-spoofing.

Keputusan akhir dihitung menggunakan rumus final score:

$$\text{final_score} = 0.7 \times \text{similarity} + 0.3 \times \text{spoof_score}$$

Pada rumus tersebut, similarity diberi bobot 70% karena berhubungan langsung dengan kecocokan identitas wajah, sedangkan spoof score diberi bobot 30% karena berhubungan dengan keaslian wajah. Sistem menerima absensi apabila memenuhi tiga syarat berikut:

1. similarity ≥ 0.75
2. spoof_score ≥ 0.85
3. final_score ≥ 0.80

Dengan pendekatan ini, sistem tidak hanya memverifikasi apakah wajah pengguna cocok dengan data yang tersimpan, tetapi juga memastikan bahwa wajah tersebut merupakan wajah asli. Hal ini membuat metode face verification menjadi lebih fleksibel dan aman dibandingkan klasifikasi identitas langsung menggunakan classifier.

2.6 Validasi Keamanan Input

Validasi keamanan input merupakan tahapan awal yang dilakukan sebelum citra diproses oleh model *Face Anti-Spoofing* dan *Face Recognition*. Tujuan utama proses ini adalah memastikan bahwa gambar yang diterima memenuhi persyaratan kualitas sehingga proses inferensi dapat dilakukan secara akurat dan menghasilkan keputusan yang andal. Dengan melakukan validasi pada tahap awal, sistem dapat mengurangi risiko kesalahan klasifikasi yang disebabkan oleh kualitas citra yang buruk maupun kegagalan deteksi wajah.

Tahap pertama yang dilakukan adalah validasi format berkas. Sistem hanya menerima citra dengan format yang didukung, seperti JPG, JPEG, PNG, dan WEBP. Setelah format dinyatakan valid, gambar didekode dan dikonversi ke ruang warna RGB agar sesuai dengan kebutuhan model pembelajaran mendalam yang digunakan pada sistem.

Selanjutnya dilakukan proses deteksi wajah menggunakan **MTCNN (Multi-task Cascaded Convolutional Networks)**. Model ini bertugas mendeteksi keberadaan wajah sekaligus menentukan posisi *bounding box* yang akan digunakan pada proses selanjutnya. Apabila tidak ditemukan wajah pada gambar, maka proses verifikasi dihentikan. Demikian pula apabila sistem mendeteksi lebih dari satu wajah, gambar akan ditolak karena proses absensi hanya diperuntukkan bagi satu pengguna dalam satu waktu.

Selain jumlah wajah, sistem juga mempertimbangkan tingkat kepercayaan (*confidence score*) hasil deteksi. Wajah hanya akan diproses apabila nilai *confidence* melebihi ambang batas yang telah ditentukan. Pendekatan ini bertujuan untuk mengurangi kemungkinan kesalahan deteksi akibat pencahayaan yang kurang baik, posisi wajah yang tidak sesuai, maupun kualitas citra yang rendah.

Setelah wajah berhasil dideteksi, sistem melakukan proses *face cropping* berdasarkan *bounding box* dengan penambahan margin tertentu agar seluruh area wajah, termasuk bagian dahi, pipi, dan dagu, tetap berada di dalam citra hasil pemotongan. Hasil *cropping* kemudian diubah ukurannya sesuai kebutuhan masing-masing model, yaitu 224×224 piksel untuk proses *Face Anti-Spoofing* dan 160×160 piksel untuk proses ekstraksi *face embedding* menggunakan FaceNet.

Tahap berikutnya adalah klasifikasi *Face Anti-Spoofing*. Pada proses ini, citra wajah dianalisis menggunakan model *weighted ensemble* untuk menentukan apakah wajah berasal dari manusia hidup (*Real*) atau media pemalsuan (*Spoof*). Apabila hasil klasifikasi menunjukkan kategori **Spoof**, proses absensi langsung dihentikan dan pengguna diminta melakukan pengambilan gambar kembali menggunakan wajah asli. Sebaliknya, apabila hasil klasifikasi menunjukkan kategori **Real**, citra diteruskan menuju proses ekstraksi *face embedding*.

Melalui tahapan validasi keamanan input tersebut, hanya citra yang memenuhi persyaratan kualitas dan dinyatakan sebagai wajah asli yang dapat diproses pada tahap verifikasi identitas. Mekanisme ini meningkatkan keandalan sistem HRIS dalam mencegah penyalahgunaan absensi menggunakan media pemalsuan sekaligus menjaga akurasi proses pengenalan wajah.

2.7 Sistem Informasi Sumber Daya Manusia (HRIS)

Human Resource Information System (HRIS) adalah perangkat lunak terintegrasi yang dirancang untuk mengelola, melacak, dan mengotomatisasi seluruh aktivitas administrasi sumber daya manusia di suatu organisasi. Komponen inti dari HRIS meliputi manajemen data pribadi, penggajian (*payroll*), manajemen performa, dan pencatatan kehadiran (presensi).

Pada industri perhotelan dengan skema kerja giliran (*shift work*) yang padat seperti di Labersa Hotel, efisiensi modul presensi HRIS sangat memengaruhi validitas perhitungan upah lembur, penilaian kedisiplinan, hingga penyusunan jadwal operasional harian. Digitalisasi HRIS yang diintegrasikan dengan teknologi biometrik nirmas merupakan langkah krusial untuk mereduksi *human error* dan birokrasi manual pada divisi *Human Resources Department* (HRD).

2.8 Evaluasi Performa Model Biometrik

Untuk mengukur kelayakan dan keandalan sistem pengenalan wajah sebelum diimplementasikan pada lingkungan produksi Labersa Hotel, digunakan beberapa metrik evaluasi standar biometrik internasional, antara lain:

1. *Accuracy*: Persentase total prediksi identitas wajah yang dilakukan secara benar oleh sistem dari keseluruhan data uji.
2. *Precision dan Recall*: *Precision* mengukur sejauh mana sistem tidak salah mengenali orang lain sebagai karyawan yang dimaksud, sedangkan *Recall* memastikan semua karyawan yang hadir dapat teridentifikasi oleh sistem.
3. *False Acceptance Rate (FAR)*: Probabilitas sistem salah mengidentifikasi wajah orang asing atau karyawan lain sebagai individu yang sah (berkaitan erat dengan celah keamanan).

4. *False Rejection Rate (FRR)*: Probabilitas sistem menolak karyawan sah yang wajahnya sebenarnya terdaftar (berkaitan erat dengan kenyamanan pengguna/antrean absensi).

BAB III

ANALISIS DAN PERANCANGAN SISTEM

3.1 Dataset

Dalam pengembangan sistem *Human Resource Information System* (HRIS) Labersa Hotel and Convention Center, aspek keamanan presensi menjadi prioritas utama. Untuk mencegah manipulasi absensi menggunakan representasi wajah tiruan, proyek ini mengimplementasikan sistem Face Anti-Spoofing (FAS) atau *Liveness Detection*. Dataset yang digunakan dalam penelitian ini merupakan data sekunder yang diunduh melalui platform Kaggle dengan karakteristik khusus yang memuat skenario serangan pemalsuan identitas (*spoof attacks*).

3.1.1 Dataset Face Recognition/ Face Verification

Dataset yang digunakan untuk kebutuhan Face Recognition dan Face Verification pada proyek ini berasal dari VGGFace2. VGGFace2 merupakan dataset wajah berskala besar yang berisi jutaan citra wajah dari ribuan identitas dengan variasi pose, ekspresi, pencahayaan, usia, dan latar belakang. Dataset ini berisi sekitar 3,31 juta citra wajah dari 9.131 identitas, dengan rata-rata sekitar 362 citra per identitas. Variasi tersebut membuat dataset ini sesuai digunakan untuk melatih model pengenalan wajah yang harus bekerja pada kondisi nyata.

Pada proyek ini, VGGFace2 digunakan sebagai dasar pelatihan model FaceNet/InceptionResnetV1. Model ini bertugas mengubah citra wajah menjadi representasi numerik berupa embedding 512 dimensi. Embedding tersebut merepresentasikan ciri khas wajah seseorang dan digunakan untuk membandingkan kemiripan antara dua wajah.

Struktur dataset VGGFace2 tersusun berdasarkan identitas, di mana setiap folder merepresentasikan satu orang atau satu kelas. Setiap folder berisi beberapa citra wajah dari orang yang sama dengan berbagai variasi kondisi pengambilan gambar. Dalam implementasi proyek ini, model face recognition menggunakan 500 kelas identitas sebagai data pelatihan.

Sebelum digunakan dalam proses training, citra wajah diproses terlebih dahulu melalui beberapa tahap. Wajah dideteksi menggunakan MTCNN, kemudian area wajah dipotong dan diubah ukurannya menjadi 160×160 piksel sesuai input FaceNet. Setelah itu, gambar dinormalisasi dan dimasukkan ke model untuk menghasilkan embedding wajah 512 dimensi.

Pada tahap training, embedding dari FaceNet digunakan oleh LightClassifier untuk mempelajari perbedaan antar identitas. Namun, pada proses absensi, sistem lebih berfokus pada pendekatan face verification, yaitu membandingkan embedding wajah baru dengan embedding wajah yang tersimpan menggunakan cosine similarity. Pendekatan ini lebih fleksibel karena sistem tidak perlu dilatih ulang setiap kali ada karyawan baru.

Meskipun VGGFace2 digunakan sebagai dataset pelatihan, dataset ini bukan merupakan dataset khusus karyawan Labersa Hotel. Oleh karena itu, pada penerapan sebenarnya, wajah karyawan tetap perlu diregistrasikan agar sistem memiliki embedding acuan yang sesuai dengan pengguna sebenarnya.

3.1.2 Dataset Anti Spoofing

Model Face Anti-Spoofing pada penelitian ini dikembangkan menggunakan dataset **LCC_FASD (Liveness Check Challenge Face Anti-Spoofing Dataset)** yang diperoleh melalui platform Kaggle. Dataset ini dirancang khusus untuk membedakan wajah asli (*live face*) dengan berbagai bentuk serangan pemalsuan (*spoof attack*) sehingga sesuai digunakan untuk melatih model klasifikasi anti-spoofing.

Dataset terdiri atas enam kategori citra, yaitu satu kategori wajah asli (*realperson*) dan lima kategori wajah tiruan (*fake*). Kelas *realperson* berisi citra wajah manusia yang diambil secara langsung menggunakan kamera, sedangkan lima kategori lainnya merepresentasikan berbagai media pemalsuan yang umum digunakan untuk menyerang sistem pengenalan wajah.

Kategori *fake_printed* berisi citra wajah yang berasal dari foto cetak (*printed attack*), *fake_screen* berisi citra wajah yang ditampilkan melalui layar perangkat elektronik (*replay attack*), *fake_mask* berisi citra wajah menggunakan topeng (*mask attack*),

fake_mannequin berisi citra wajah dari manekin atau patung, sedangkan *fake_unknown* berisi berbagai bentuk serangan lain yang tidak termasuk ke dalam kategori sebelumnya.

Meskipun dataset memiliki enam kategori, proses pelatihan model anti-spoofing pada penelitian ini menggunakan pendekatan klasifikasi biner (*binary classification*). Seluruh data pada kelas *realperson* diberi label **Real**, sedangkan seluruh kelas *fake* digabungkan menjadi label **Spoof**. Pendekatan ini dipilih karena tujuan utama sistem bukan untuk mengidentifikasi jenis serangan yang digunakan, melainkan menentukan apakah wajah yang digunakan saat proses absensi merupakan wajah asli atau media pemalsuan.

Penggunaan dataset dengan variasi jenis serangan yang beragam memungkinkan model mempelajari karakteristik tekstur, warna, pencahayaan, serta pola visual yang membedakan wajah hidup dengan berbagai media spoofing. Dengan demikian, model diharapkan memiliki kemampuan generalisasi yang lebih baik ketika diimplementasikan pada lingkungan operasional HRIS.

3.2 Arsitektur Sistem

Arsitektur sistem terdiri atas beberapa komponen utama yang bekerja secara berurutan mulai dari penerimaan citra hingga proses verifikasi identitas pengguna. Setiap komponen memiliki fungsi yang saling terintegrasi sehingga mampu menghasilkan proses autentikasi yang aman dan akurat.

Komponen	Fungsi	Teknologi
Input Gambar	Mengambil foto selfie saat registrasi/absensi	JPG, JPEG, PNG, WEBP
Face Detector	Mendeteksi wajah dan bounding box	MTCNN
Face Validation	Memastikan hanya satu wajah dan confidence cukup	Rule-Based Verification

Komponen	Fungsi	Teknologi
Accessory Detection	Mendeteksi masker, kacamata, dan topi	OpenCV, HSV/LAB, Edge Detection
Face Anti-Spoofing	Mengklasifikasikan wajah menjadi Real atau Spoof	Weighted Ensemble (MiniFASNet, FLRGB, ICM2O, IOM2C, CDCN++)
Feature Extractor	Menghasilkan embedding 512 dimensi	FaceNet/InceptionResnetV1
Verification	Membandingkan wajah baru dengan stored embedding	Cosine Similarity
Decision	Menggabungkan similarity dan spoof score	Final Score

Alur kerja sistem dimulai ketika pengguna mengambil foto wajah melalui aplikasi mobile. Gambar yang diterima terlebih dahulu menjalani proses deteksi wajah menggunakan MTCNN untuk memperoleh lokasi wajah pada citra. Area wajah kemudian dipotong (*cropping*), diubah ukurannya sesuai kebutuhan model, dan dinormalisasi sebelum memasuki tahap inferensi.

Tahap berikutnya adalah proses Face Anti-Spoofing menggunakan pendekatan weighted ensemble. Seluruh model anti-spoofing melakukan inferensi terhadap citra secara independen dan menghasilkan probabilitas untuk kelas Real maupun Spoof. Probabilitas tersebut kemudian digabungkan menggunakan mekanisme pembobotan sehingga diperoleh keputusan akhir mengenai keaslian wajah.

Apabila hasil klasifikasi menunjukkan kategori Spoof, proses absensi langsung dihentikan. Sebaliknya, apabila hasil klasifikasi menunjukkan kategori Real, citra diteruskan ke model FaceNet untuk menghasilkan embedding wajah berdimensi 512. Embedding tersebut dibandingkan dengan embedding yang tersimpan pada basis data

menggunakan metode cosine similarity sehingga diperoleh tingkat kemiripan identitas. Hasil perbandingan tersebut selanjutnya digunakan sebagai dasar keputusan akhir proses verifikasi pengguna.

3.3 Arsitektur Model LightClassifier

LightClassifier digunakan pada tahap training untuk melatih representasi identitas dari embedding FaceNet. Namun, pada proses absensi, sistem menggunakan pendekatan face verification, yaitu membandingkan embedding wajah baru dengan embedding wajah yang telah tersimpan menggunakan cosine similarity. Pendekatan ini lebih fleksibel karena tidak perlu melakukan retraining ketika ada karyawan baru. Arsitektur lengkap:

Layer	Input Dim	Output Dim	Aktivasi
Linear 1	512	256	GELU
Batch Normalization	256	256	—
Dropout	256	256	$p = 0.5$
Linear 2	256	128	GELU
Batch Normalization	128	128	—
Dropout	128	128	$p = 0.3$
Linear 3 (Output)	128	N kelas	Softmax

3.3 Perancangan Basis Data (*Database Design*)

Sistem HRIS Labersa Hotel mengimplementasikan basis data non-relasional (NoSQL) berbasis dokumen untuk mengelola klaster data biometrik karyawan. Pendekatan ini dipilih karena struktur data dokumen memungkinkan penyimpanan vektor fitur (embedding array) berdimensi tinggi secara langsung tanpa memerlukan tabel junction terpisah, sehingga mempercepat waktu kueri pencocokan (vector similarity search).

3.3.1 Skema Koleksi Face Profiles (face_embedding)

Koleksi ini menyimpan representasi matematis wajah karyawan beserta metadata operasional untuk keperluan validasi *log* absensi. Berikut adalah spesifikasi kamus data berdasarkan struktur dokumen NoSQL yang diterapkan:

Field/Kunci	Tipe Data	Keterangan
_id	ObjectId (PK)	Identifikasi unik dokumen profil wajah (berbasis hash hex)
user_id	ObjectId	Referensi silang ke dokumen utama identitas karyawan
face_embedding	Array (Double)	Vektor fitur 512 dimensi hasil ekstraksi model FaceNet
face_image_url	String	URL penyimpanan <i>cloud storage</i> (Supabase Bucket) untuk foto master
is_active	Boolean	Status keaktifan data biometrik karyawan (true/false)
is_first_login	Boolean	Penanda apakah karyawan baru pertama kali melakukan registrasi
registered_at	DateTime	Waktu pertama kali biometrik wajah didaftarkan ke sistem

Field/Kunci	Tipe Data	Keterangan
verification_count	Integer	Total akumulasi keberhasilan verifikasi absensi karyawan
created_at	DateTime	Timestamp pembuatan record dokumen
updated_at	DateTime	Timestamp pembaruan terakhir data biometrik
last_verified_at	DateTime	Riwayat waktu terakhir kali karyawan berhasil melakukan absensi

3.5 Perancangan Antarmuka (*User Interface Design*)

Perancangan antarmuka terminal absensi ditekankan pada aspek kesederhanaan dan kejelasan informasi (*user-centric design*) agar operasional harian karyawan di Labersa Hotel and Convention Center berjalan efisien. Antarmuka aplikasi terminal dirancang ke dalam 3 (tiga) status representasi kondisi sistem:

3.5.1 Antarmuka Terminal Siaga (*Standby & Scanning Mode*)

Merupakan halaman utama sistem yang aktif memindai wajah karyawan di lobi hotel.

- Umpan Kamera & *Overlay*: Menampilkan video *real-time* dengan bingkai panduan berbentuk oval di tengah layar untuk memosisikan wajah.
- Teks Panduan: Petunjuk visual di bagian bawah layar yang berbunyi: "*Harap Posisikan Wajah Anda di Dalam Area Bingkai dan Lepaskan Masker/Kacamata*".

3.5.2 Antarmuka Verifikasi Berhasil (*Success Attendance View*)

Halaman konfirmasi transisi yang muncul selama 3 detik setelah identitas wajah karyawan berhasil divalidasi oleh sistem.

- Indikator Visual: Didominasi aksen warna hijau dengan ikon centang (*check-mark*) besar.
- Informasi Karyawan: Menampilkan foto profil dari Supabase, nama lengkap, Nomor Induk Karyawan (NIK), divisi, serta waktu kehadiran yang tercatat.
- Pesan Sukses: *"Absensi Berhasil Tercatat. Selamat Bekerja!"*

3.5.3 Antarmuka Penolakan Keamanan & Atribut (*Rejection & Fraud Warning View*)

Halaman peringatan yang dipicu jika pengguna tidak memenuhi syarat atribut atau terdeteksi melakukan kecurangan (*spoofing*).

- Indikator Peringatan: Didominasi aksen warna merah/jingga dengan ikon segitiga peringatan.
- Kendala Atribut: *"Akses Ditolak: Terdeteksi penggunaan kacamata/masker. Harap lepas aksesoris Anda."*
- Deteksi Kecurangan: *"Aktivitas Mencurigakan Terdeteksi: Harap lakukan verifikasi menggunakan wajah asli secara langsung di depan kamera!"*

BAB IV

IMPLEMENTASI

4.1 Preprocessing Data

Tahap preprocessing dilakukan untuk memastikan bahwa citra yang diterima memiliki kualitas yang sesuai sebelum diproses oleh model pembelajaran mendalam. Seluruh citra terlebih dahulu dikonversi ke ruang warna RGB, kemudian dilakukan deteksi wajah menggunakan MTCNN. Setelah wajah berhasil dideteksi, sistem melakukan proses *cropping* berdasarkan *bounding box* dengan penambahan margin agar seluruh area wajah tetap tercakup.

Citra hasil *cropping* kemudian diubah ukurannya sesuai kebutuhan masing-masing model. Untuk proses Face Anti-Spoofing digunakan ukuran 224×224 piksel, sedangkan untuk proses ekstraksi embedding menggunakan FaceNet digunakan ukuran 160×160 piksel. Setelah proses *resize*, citra dinormalisasi sehingga memiliki distribusi data yang sesuai dengan model yang digunakan.

Tahap preprocessing ini bertujuan menghasilkan representasi citra yang konsisten sehingga model mampu melakukan klasifikasi secara lebih stabil terhadap berbagai variasi pencahayaan, posisi wajah, maupun kualitas gambar.

4.1.1 Lokalisasi dan Ekstraksi Wajah (*Face Cropping*)

Deteksi wajah dilakukan menggunakan algoritma MTCNN untuk mengisolasi area wajah dari latar belakang gambar. Berdasarkan fungsi `_crop_largest_face_rgb`, jika terdapat beberapa objek pada citra, sistem secara otomatis mengekstrak kotak pembatas (*bounding box*) terbesar dengan menambahkan batas aman (*margin*) sebesar 15% guna memastikan komponen penanda wajah penting tidak terpotong. Citra hasil pemotongan (*crop*) kemudian dikonversi ke dalam ruang warna RGB sebelum diteruskan ke tahap transformasi berikutnya.

4.1.2 Penyeragaman Dimensi (*Resizing*) dan Pembagian Data Terstratifikasi (*Stratified Split*)

Setiap citra wajah yang telah diekstrak dilewati ke dalam fungsi generator untuk diubah ukurannya (*resize*) secara seragam menjadi dimensi 224 x 224 piksel, menyesuaikan dengan standar arsitektur tulang punggung (*backbone*) Anti-Spoofing Ensemble dan FaceNet.

Untuk menjamin evaluasi performa model yang objektif dan menghindari bias akibat ketidakseimbangan jumlah data (terutama pada variasi data *spoofing*), pembagian data dilakukan menggunakan metode **Stratified Sampling** dengan rasio proporsi:

- Dataset Pelatihan (*Training Set*): 80% dari total populasi data.
- Dataset Validasi (*Validation Set*): 20% dari total populasi data.

4.1.3 Pipeline Transformasi dan Augmentasi Citra

Sistem menerapkan dua strategi transformasi yang berbeda secara kontras berdasarkan fase eksekusi dan kebutuhan spesifik arsitektur model:

1. Pipeline Augmentasi Pelatihan Anti-Spoofing (Agresif)

Untuk meminimalkan celah overfitting terhadap distorsi fisik media cetak (printed attack) maupun layar digital (screen attack), citra dimanipulasi menggunakan kombinasi fungsi transforms.RandomResizedCrop (skala 0.7 hingga 1.0), RandomHorizontalFlip ($p=0.5$), RandomVerticalFlip ($p=0.1$), dan RandomRotation (rentang derajat ± 20). Selain itu, diterapkan pula ColorJitter (distorsi kecerahan, kontras, dan saturasi sebesar 35%, serta hue 20%), GaussianBlur (kernel 5, rentang $\sigma \in [0.1, 0.3]$) untuk simulasi hilangnya fokus kamera, serta efek RandomErasing ($p=0.25$) untuk melatih ketahanan model terhadap oklusi parsial pada area wajah.

2. Pipeline Augmentasi Pelatihan Face Recognition (Geometris Terkontrol)

Untuk tugas pengenalan identitas wajah, augmentasi dibatasi secara ketat agar tidak merusak esensi fitur biometrik unik (seperti geometri jarak mata dan hidung). Transformasi hanya melibatkan RandomCrop, RandomHorizontalFlip

($p=0.5$), rotasi ringan (RandomRotation $\pm 20^\circ$), dan ColorJitter dengan parameter moderat (20%).

3. Pipeline Validasi dan Inferensi Real-Time

Citra diolah tanpa melibatkan komponen stokastik/acak. Pemrosesan murni menggunakan fungsi `transforms.Resize` dan `transforms.CenterCrop` untuk menghasilkan dimensi 224×224 piksel yang konsisten secara deterministik.

4.1.4 Standardisasi dan Normalisasi Nilai Piksel

Sebelum dikonversi menjadi representasi matriks Tensor PyTorch, nilai intensitas piksel citra yang berada pada rentang $[0, 255]$ dinormalisasi ke dalam skala float $[0.0, 1.0]$. Selanjutnya, dilakukan operasi standardisasi menggunakan parameter distribusi statistik dari dataset ImageNet melalui persamaan berikut:

$$\chi = \frac{\chi - \mu}{\sigma}$$

Di mana nilai rata-rata (μ) ditetapkan sebesar $[0.485, 0.456, 0.406]$ dan simpangan baku (σ) sebesar $[0.229, 0.224, 0.225]$ untuk masing-masing kanal saluran warna (R, G, B). Langkah ini memastikan distribusi data input bersifat zero-centered guna menstabilkan gradien selama proses backpropagation.

4.1.5 Regulasi Batch Tingkat Lanjut (*Advanced Regularization*)

Pada fase pelatihan data *anti-spoofing*, diterapkan dua teknik regulasi modern secara simultan untuk menekan angka *overfitting gap*:

1. MixUp Augmentation: Menggabungkan pasangan data input dan label dalam satu *batch* secara linear berdasarkan koefisien interpolasi dengan nilai $\alpha = 0.3$. Proses ini memaksa model untuk membentuk batas keputusan (*decision boundary*) yang halus dan linear.
2. Label Smoothing Regularization: Mengubah distribusi target biner mutlak $[1, 0]$ menjadi target probabilitas halus dengan faktor penyimpangan $\epsilon = 0.2$. Untuk tugas klasifikasi biner, label *ground-truth* dikonversi secara matematis menjadi 1 -

$\epsilon = 0.9$ untuk kelas positif dan $\epsilon / K = 0.1$ untuk kelas negatif, yang berkontribusi langsung dalam mencegah perilaku model yang terlalu percaya diri (*overconfident*).

4.2 Feature Engineering & Selection

Pada model Face Anti-Spoofing, proses ekstraksi fitur dilakukan secara otomatis oleh jaringan saraf yang tergabung dalam mekanisme weighted ensemble. Setiap model mempelajari karakteristik tekstur permukaan wajah, distribusi warna, pola pencahayaan, serta informasi spasial yang dapat membedakan wajah asli dengan berbagai bentuk media pemalsuan.

Hasil ekstraksi fitur dari masing-masing model kemudian digunakan untuk menghasilkan probabilitas terhadap kelas Real dan Spoof. Selanjutnya, probabilitas tersebut digabungkan menggunakan mekanisme weighted ensemble sehingga keputusan klasifikasi tidak bergantung pada satu model saja. Pendekatan ini meningkatkan kemampuan generalisasi sistem terhadap berbagai variasi serangan spoofing sekaligus mengurangi kemungkinan kesalahan klasifikasi akibat karakteristik data tertentu..

4.2.1 Ekstraksi dan Rekayasa Embedding Wajah (*Face Embedding Engineering*)

Pada pipeline *Face Recognition*, rekayasa fitur diwujudkan dengan mentransformasikan citra piksel wajah berdimensi tinggi menjadi sebuah vektor *embedding* kompak berdimensi rendah, yaitu sebesar 128 atau 512 dimensi menggunakan arsitektur FaceNet. Melalui mekanisme ini, model memetakan karakteristik topologi wajah seperti jarak antar mata, posisi hidung, dan garis rahang ke dalam ruang vektor euklidian (*Euclidean space*). Kedekatan geometris dalam ruang vektor tersebut secara langsung merepresentasikan kemiripan identitas visual, sehingga variasi ekspresi, sudut pandang, maupun pencahayaan pada individu yang sama akan dipetakan ke dalam koordinat vektor yang berdekatan untuk optimasi fitur yang maksimal.

4.2.2 Pemilihan Fitur Otomatis Lewat Lapisan Konvolusi (*Deep Feature Selection*)

Pemilihan fitur yang paling relevan dilakukan secara berlapis melalui ekstraksi hierarkis pada komponen *backbone* Anti-spoofing Ensemble untuk *Anti-Spoofing* dan FaceNet

untuk *Face Recognition*. Lapisan dangkal (*shallow layers*) bertugas memilih dan mempertahankan fitur-fitur geometris dasar dan tekstur frekuensi tinggi seperti tepian objek, pola garis, dan kontras mikro yang sangat relevan untuk mendeteksi artefak refleksi layar digital atau garis potong kertas pada kasus *spoofing*. Sementara itu, lapisan dalam (*deep layers*) melakukan seleksi terhadap fitur semantik tingkat tinggi seperti bentuk komponen wajah secara utuh dan mengabaikan informasi latar belakang (*background noise*) yang tidak relevan, sehingga kompleksitas komputasi model dapat dipangkas secara signifikan.

4.2.3 Reduksi Dimensi Menggunakan Lapisan *Global Average Pooling* (GAP)

Untuk meminimalkan risiko *overfitting* akibat terlalu banyaknya parameter pada lapisan akhir (*fully connected layer*), sistem menerapkan teknik pemilihan fitur spasial menggunakan *Global Average Pooling* (GAP) tepat sebelum blok klasifikasi. Mekanisme GAP ini bekerja dengan mereduksi peta fitur tensor tiga dimensi ($C \times H \times W$) menjadi vektor satu dimensi ($C \times 1 \times 1$) dengan mengambil nilai rata-rata dari seluruh dimensi spasial ($H \times W$). Proses ini secara drastis memilih informasi spasial yang paling dominan, mengurangi kompleksitas arsitektur model, serta membuat model menjadi lebih kebal terhadap pergeseran posisi objek atau *spatial translations*.

4.2.4 Seleksi Fitur Adaptif Melalui Regularisasi L2 (*Weight Decay*)

Sebagai bagian dari penentuan fitur yang paling relevan, sistem menerapkan regularisasi L2 (*weight decay*) sebesar 1×10^{-3} pada fungsi optimasi AdamW. Secara matematis, regularisasi ini memberikan penalti terhadap bobot (*weights*) model yang bernilai terlalu besar selama proses pelatihan berlangsung. Dampaknya, fitur-fitur yang dinilai mengandung *noise* atau tidak berkontribusi signifikan terhadap akurasi prediksi, seperti detail *noise* acak pada latar belakang gambar, secara otomatis diredam bobotnya mendekati nol, sehingga hanya fitur biometrik dan tekstur paling kuat yang dipertahankan untuk menyusun keputusan klasifikasi akhir.

4.3 Data Splitting

Tahapan pembagian data (*data splitting*) dilakukan untuk memisahkan seluruh sampel citra yang tersedia menjadi beberapa subset independen, yaitu dataset pelatihan (*training*

set), dataset validasi (*validation set*), dan dataset pengujian (*test set*). Pemisahan ini merupakan langkah krusial dalam metodologi *deep learning* untuk menjamin bahwa proses evaluasi performa model dilakukan secara objektif serta mampu mengukur kemampuan generalisasi model terhadap data baru yang belum pernah dilihat sebelumnya (*unseen data*). Dengan memisahkan data evaluasi dari data pelatihan, risiko bias estimasi atau fenomena menghafal pola data (*overfitting*) dapat dihindari secara optimal.

4.3.1 Penerapan Stratified Sampling untuk Keseimbangan Kelas

Penerapan pembagian data dalam sistem ini mengintegrasikan pendekatan berbasis *Stratified Sampling* untuk menjaga keseimbangan distribusi kelas di setiap subset hasil pemisahan. Pada tugas klasifikasi *Anti-Spoofing*, ketidakseimbangan kelas bawaan, di mana total sampel dari lima kategori serangan *spoof* jauh melampaui jumlah sampel wajah asli (*realperson*)—diatasi secara presisi dengan mengunci rasio distribusi melalui parameter stratifikasi berbasis label target. Pemisahan data dirancang dengan skema alokasi proporsi 80% untuk kebutuhan optimasi internal (pelatihan dan validasi) dan 20% sisa data yang dialokasikan khusus sebagai dataset pengujian mandiri untuk menguji performa akhir model sebelum diimplementasikan pada lingkungan produksi.

4.3.2 Konfigurasi Pembagian dan Reprodusibilitas Sistem

Proses pembagian data internal untuk fase pencarian bobot dan parameter model menggunakan rasio pemisahan sekunder sebesar 80:20 dari total alokasi data latih utama. Fungsi `train_test_split` dari pustaka *Scikit-Learn* diimplementasikan dengan argumen `stratify=labels` dan dikunci menggunakan konfigurasi `random_state=42` demi menjamin sifat reprodusibilitas pembagian indeks tensor pada setiap komputasi. Melalui mekanisme ini, dataset pelatihan (*training set*) mendapatkan porsi penuh untuk memicu pembaruan bobot arsitektur via *backpropagation*, sedangkan dataset validasi (*validation set*) berfungsi sebagai pemantau metrik kerugian (*loss*) secara berkala di setiap akhir *epoch* sekaligus menjadi pemicu utama bagi fungsi penghentian dini (*early stopping*) apabila model terdeteksi mengalami stagnasi performa dalam dua puluh *epoch* berturut-turut.

4.4 Training Model

Pelatihan model Face Anti-Spoofing dilakukan menggunakan dataset LCC_FASD yang telah diproses melalui tahap preprocessing. Seluruh citra dibagi ke dalam data pelatihan dan data validasi untuk mengukur kemampuan generalisasi model selama proses pembelajaran.

Berbeda dengan pendekatan yang hanya menggunakan satu model klasifikasi, penelitian ini menerapkan beberapa model Face Anti-Spoofing yang bekerja secara independen. Setiap model mempelajari karakteristik visual yang berbeda sehingga mampu mengenali berbagai variasi serangan spoofing. Setelah seluruh model selesai dilatih, hasil prediksi masing-masing model digabungkan menggunakan mekanisme weighted ensemble untuk menghasilkan keputusan klasifikasi akhir.

Pendekatan ensemble dipilih karena mampu meningkatkan stabilitas prediksi dibandingkan penggunaan model tunggal. Selain meningkatkan akurasi klasifikasi, pendekatan ini juga membuat sistem lebih adaptif terhadap variasi pencahayaan, kualitas citra, maupun jenis media spoofing yang digunakan selama proses pengujian. Guna memastikan efisiensi tingkat tinggi dan generalisasi yang kuat, proses pelatihan dikonfigurasi melalui rincian tabel *hyperparameter* berikut:

Hyperparameter	Nilai	Keterangan
Jumlah Epoch (max)	50	Dengan early stopping patience=10
Batch Size	128	Efektif 512 dengan grad accumulation
Gradient Accumulation	4	Simulasi batch size lebih besar
Learning Rate (max)	3e-3	OneCycleLR dengan warmup 30%
Label Smoothing	0.1	Regularisasi anti-overconfidence
Presisi Komputasi	bfloat16	Lebih cepat di CPU modern

Hyperparameter	Nilai	Keterangan
Optimizer	AdamW	Weight decay = 1e-4

4.4.1 Implementasi Strategi Pre-Computing Embeddings

Pelatihan model dilakukan sepenuhnya menggunakan pemroses sentral (CPU) dengan menerapkan teknik optimasi khusus berupa *pre-computing embeddings*. Pada awal siklus, arsitektur FaceNet dieksekusi tepat satu kali untuk memproses seluruh sampel citra wajah di dalam dataset dan mengekstrak vektor fiturnya. Hasil ekstraksi berupa representasi *embedding* tersebut kemudian disimpan langsung ke dalam media penyimpanan lokal sebagai berkas *cache* terkompresi berformat .npz. Memasuki *epoch* kedua hingga akhir fase pelatihan, model tidak lagi melakukan komputasi konvolusi wajah dari awal, melainkan langsung membaca data fitur dari berkas *cache* tersebut. Strategi ini secara drastis memangkas beban kerja CPU (*computational overhead*) dan mempercepat durasi pelatihan secara signifikan di lingkungan *CPU-only*.

4.4.1 Mekanisme Simulasi Batch Lewat Gradient Accumulation dan bfloat16

Keterbatasan memori pada perangkat CPU diatasi dengan menerapkan teknik *Gradient Accumulation* dengan faktor perkalian 4. Melalui metode ini, model memproses *batch size* riil sebesar 128 sampel, namun menunda pembaruan bobot (*weight update*) hingga gradien dari 4 *mini-batch* terkumpul berturut-turut, sehingga berhasil mensimulasikan efek stabilisasi dari *batch size* besar bernilai 512 tanpa memicu lonjakan penggunaan memori. Kecepatan pemrosesan ini dioptimalkan lebih lanjut menggunakan operasi presisi campuran (*mixed-precision computation*) berbasis format bfloat16 (Brain Floating Point). Format ini memotong kebutuhan bandwidth memori menjadi setengah dari format standar float32 dengan tetap mempertahankan rentang dinamis nilai numerik yang aman, sehingga instruksi vektor pada CPU modern dapat dieksekusi dengan performa maksimal.

4.4.2 Penjadwalan Dinamis OneCycleLR dan Regulasi Early Stopping

Untuk menghindari fenomena ledakan gradien (*exploding gradients*) serta menjamin konvergensi yang mulus pada nilai *learning rate* tinggi, sistem menerapkan algoritma

penjadwalan OneCycleLR. Penjadwalan ini memulai pelatihan dengan *learning rate* rendah, menaikkannya secara agresif hingga mencapai nilai maksimum 3×10^{-3} selama 30% fase pertama (*warmup*), kemudian menurunkan secara kosinus mendekati nol pada sisa *epoch*. Selama proses ini berlangsung, fungsi *early stopping* dengan parameter *patience* sebesar 10 secara kontinu memantau pergerakan nilai *validation loss*. Ketika grafik kerugian pada data validasi tidak menunjukkan penurunan performa yang lebih baik selama 10 *epoch* berturut-turut, sistem secara otomatis memicu interupsi penghentian di *epoch* ke-43 guna menyelamatkan model dari gejala *overfitting*.

4.5 Hyperparameter Tuning

Setelah kerangka pelatihan model terbentuk, tahapan selanjutnya adalah melakukan optimasi parameter internal model melalui proses *Hyperparameter Tuning*. Pada sistem ini, pencarian kombinasi parameter terbaik berfokus pada minimalisasi celah *overfitting* serta peningkatan nilai akurasi dan *F1-score* secara simultan pada tugas klasifikasi *Anti-Spoofing* dan *Face Recognition*. Pengujian fasa optimasi ini membandingkan efisiensi antara metode *Grid Search* dan *Random Search* untuk menemukan nilai parameter arsitektur yang paling adaptif terhadap karakteristik dataset biometrik wajah.

4.5.1 Komparasi Metodologi Grid Search dan Random Search

Sistem mengevaluasi dua pendekatan utama dalam ruang pencarian parameter, yaitu *Grid Search* dan *Random Search*. Metode *Grid Search* bekerja secara komprehensif dengan menguji setiap kombinasi nilai parameter yang telah ditentukan di dalam ruang matriks Cartesian, seperti kombinasi nilai *learning rate* $\in [1 \times 10^{-3}, 3 \times 10^{-3}, 5 \times 10^{-3}]$ dan nilai *dropout rate* $\in [0.4, 0.5, 0.6]$. Meskipun *Grid Search* menjamin penemuan nilai optimum global di dalam ruang lingkup grid tersebut, biaya komputasi yang dibutuhkan sangat tinggi. Sebagai alternatif efisien di lingkungan *CPU-only*, diterapkan metode *Random Search* yang memilih kombinasi parameter secara acak berdasarkan distribusi probabilitas statistik tertentu dalam jumlah iterasi yang dibatasi, sehingga mampu menemukan konfigurasi parameter yang mendekati optimal dalam waktu yang jauh lebih singkat.

4.5.2 Tuning Parameter Regularisasi dan Augmentasi

Fokus utama dari proses *tuning* ini adalah mengoptimalkan parameter pertahanan model terhadap serangan *spoofing* yang memiliki variasi visual tak terduga. Eksperimen dilakukan dengan menala koefisien intensitas *MixUp alpha* (α) pada rentang 0.1 hingga 0.4, di mana nilai $\alpha = 0.3$ terpilih karena menghasilkan perpaduan gambar yang paling optimal tanpa mengaburkan batas keputusan kelas. Selain itu, parameter *dropout rate* pada lapisan pengklasifikasi *Anti-Spoofing* disesuaikan secara bertingkat dari 0.4 hingga 0.6. Hasil pengujian menunjukkan bahwa nilai *dropout* agresif sebesar 0.6 pada lapisan pertama yang dikombinasikan dengan pembagian fraksional pada lapisan berikutnya sukses menekan angka deviasi akurasi antara data training dan validasi.

4.5.3 Optimalisasi Penjadwalan Learning Rate dan Fungsi Kehilangan

Langkah terakhir dari tahapan *hyperparameter tuning* adalah menyelaraskan interaksi antara fungsi penurunan gradien dan fungsi loss target. Melalui beberapa iterasi pengujian, batas atas *learning rate* pada konfigurasi OneCycleLR dioptimalkan pada nilai maksimum 3×10^{-3} dengan proporsi fase *warmup* sebesar 30%, yang terbukti mempercepat pencapaian titik konvergensi stabil pada CPU tanpa mengalami gejala *gradient vanishing*. Parameter penghalusan pada fungsi *Label Smoothing* juga dinala antara nilai 0.05 hingga 0.20. Pengondisian akhir menetapkan nilai $\epsilon = 0.1$ untuk model *Face Recognition* guna mempertahankan ketajaman fitur identitas, dan nilai $\epsilon = 0.2$ untuk model *Anti-Spoofing* demi memberikan ruang toleransi yang lebih tinggi terhadap noise tekstur citra tiruan.

4.6 Model Evaluation

Evaluasi model Face Anti-Spoofing dilakukan menggunakan metrik yang umum digunakan pada sistem biometrik, yaitu **Attack Presentation Classification Error Rate (APCER)**, **Bona Fide Presentation Classification Error Rate (BPCER)**, dan **Average Classification Error Rate (ACER)**.

APCER digunakan untuk mengukur kemampuan model dalam mendeteksi berbagai bentuk serangan spoofing. Nilai APCER yang rendah menunjukkan bahwa sebagian besar media pemalsuan berhasil dikenali sebagai Spoof.


BPCER digunakan untuk mengukur tingkat kesalahan model dalam mengklasifikasikan wajah asli sebagai Spoof. Semakin kecil nilai BPCER, semakin baik kemampuan sistem dalam menerima pengguna yang sah tanpa menghasilkan penolakan yang tidak diperlukan.

Sementara itu, ACER merupakan rata-rata dari APCER dan BPCER yang digunakan sebagai indikator performa keseluruhan model Face Anti-Spoofing. Nilai ACER yang rendah menunjukkan bahwa model memiliki keseimbangan yang baik antara kemampuan mendeteksi serangan spoofing dan kemampuan menerima wajah asli.

Penggunaan ketiga metrik tersebut memberikan gambaran yang lebih komprehensif mengenai performa model dibandingkan hanya menggunakan nilai akurasi, karena sistem anti-spoofing harus mempertimbangkan keseimbangan antara aspek keamanan dan kenyamanan pengguna.


4.6.1 Analisis Metrik Akurasi Tingkat Makro dan Sektoral

Sistem mengukur performa generalisasi model menggunakan kombinasi metrik akurasi global dan sektoral untuk menghindari bias interpretasi data. Berdasarkan hasil pengujian eksperimen, model berhasil membukukan nilai akurasi pengujian (*Test Accuracy*) sebesar 96,12%, yang sejalan dengan performa akurasi validasi terbaiknya di angka 96,30%. Validasi performa yang seimbang ini diperkuat oleh nilai rata-rata akurasi per kelas (*Mean Class Accuracy*) sebesar 96,18%, yang mengonfirmasi bahwa kemampuan model dalam mengenali karakteristik biometrik wajah terdistribusi secara merata di seluruh subfolder identitas tanpa mengalami penurunan performa ekstrem pada kelas-kelas tertentu.




4.6.2 Evaluasi Keseimbangan Prediksi Lewat F1-Score Weighted dan Macro

Untuk mengukur ketepatan klasifikasi pada seluruh arsitektur multi-kelas, sistem mengintegrasikan metrik *F1-Score* dengan pendekatan bobot (*Weighted*) dan rata-rata tidak berbobot (*Macro*). Model mencatatkan nilai *Test F1-Score Weighted* yang sangat tinggi sebesar 96,98%, menandakan bahwa mayoritas sampel di dalam populasi data uji berhasil diklasifikasikan ke dalam label identitas yang tepat dengan tingkat presisi dan reliabilitas tinggi. Di sisi lain, metrik *Test F1-Score Macro* berada pada angka 43,88%; deviasi nilai *macro* yang lebih rendah ini mendokumentasikan adanya *noise* minor atau fluktuasi distribusi jumlah sampel pada sebagian kecil folder identitas, namun tidak mendegradasi keandalan fungsionalitas sistem secara keseluruhan yang direpresentasikan oleh performa *weighted* yang solid.



4.6.3 Analisis Kurva Pelatihan dan Validasi Overfitting Gap

Langkah terakhir dari tahapan evaluasi adalah menganalisis stabilitas grafik performa sepanjang 50 *epoch* masa pelatihan dengan total waktu komputasi selama 123,7 menit. Berdasarkan data historis pelatihan, model mencapai titik konvergensi nilai kerugian validasi terbaik (*Best Validation Loss*) sebesar 1,3230, yang berbanding lurus dengan grafik penurunan *training loss*. Selisih antara akurasi validasi terbaik (96,30%) dan akurasi pengujian akhir (96,12%) menunjukkan *Overfitting Gap* yang sangat tipis, yaitu sebesar 0,18%. Jarak margin yang sangat sempit ini membuktikan secara empiris bahwa implementasi arsitektur *LightClassifier* bersama teknik regulasi *Label Smoothing* berhasil menekan sifat *overconfidence* model, sehingga menghasilkan model yang siap diimplementasikan pada lingkungan produksi nyata (*real-time inference*).



4.7 Implementasi Verifikasi Wajah

Tahap verifikasi wajah merupakan proses akhir yang mengintegrasikan mekanisme Face Anti-Spoofing dan Face Recognition dalam satu alur autentikasi. Tujuan utama tahapan ini adalah memastikan bahwa pengguna yang melakukan absensi merupakan individu yang sah serta menggunakan wajah asli yang berada secara langsung di depan kamera.

Proses dimulai ketika pengguna mengambil foto wajah melalui aplikasi HRIS. Citra yang diterima terlebih dahulu diperiksa menggunakan MTCNN untuk mendeteksi lokasi wajah. Apabila tidak ditemukan wajah atau terdeteksi lebih dari satu wajah, proses verifikasi langsung dihentikan dan pengguna diminta mengambil ulang gambar.

Setelah wajah berhasil dideteksi, sistem melakukan proses *face cropping* dan *preprocessing* berupa perubahan ukuran citra serta normalisasi sesuai kebutuhan model. Citra hasil *preprocessing* kemudian diproses oleh model Face Anti-Spoofing berbasis *weighted ensemble*.

Pada tahap Face Anti-Spoofing, beberapa model melakukan inferensi secara independen terhadap citra wajah. Masing-masing model menghasilkan probabilitas terhadap kelas **Real** dan **Spoof**. Probabilitas tersebut kemudian digabungkan menggunakan mekanisme pembobotan (*weighted ensemble*) sehingga diperoleh keputusan akhir mengenai keaslian wajah.

Apabila hasil klasifikasi menunjukkan kategori **Spoof**, sistem langsung menghentikan proses absensi dan mengembalikan pesan bahwa wajah tidak dapat diverifikasi karena terindikasi menggunakan media pemalsuan. Sebaliknya, apabila wajah diklasifikasikan

sebagai **Real**, proses dilanjutkan menuju tahap ekstraksi *face embedding* menggunakan FaceNet (InceptionResnetV1).

Model FaceNet menghasilkan representasi numerik wajah berupa *embedding* berdimensi 512. Embedding tersebut dibandingkan dengan *embedding* referensi yang telah tersimpan pada basis data menggunakan metode *cosine similarity*. Nilai *similarity* yang diperoleh menunjukkan tingkat kemiripan antara wajah yang baru diambil dengan wajah yang telah diregistrasikan sebelumnya.

Keputusan akhir verifikasi ditentukan berdasarkan nilai *cosine similarity* yang diperoleh. Apabila nilai kemiripan memenuhi atau melebihi ambang batas yang telah ditentukan, identitas pengguna dinyatakan valid dan proses absensi berhasil disimpan ke dalam sistem. Sebaliknya, apabila nilai *similarity* berada di bawah ambang batas, proses verifikasi dinyatakan gagal karena wajah tidak sesuai dengan data biometrik yang tersimpan.

Dengan pendekatan bertingkat tersebut, proses autentikasi tidak hanya memverifikasi identitas pengguna, tetapi juga memastikan bahwa identitas tersebut berasal dari wajah asli. Pendekatan ini meningkatkan keamanan sistem terhadap berbagai bentuk serangan *presentation attack* tanpa mengurangi akurasi proses pengenalan wajah.

BAB V


HASIL DAN ANALISIS

5.1 Lingkungan Eksperimen dan Dataset Pengujian

Pengujian sistem dilakukan untuk mengevaluasi performa model Face Anti-Spoofing dan Face Recognition sebelum diintegrasikan ke dalam sistem HRIS. Seluruh eksperimen dilaksanakan menggunakan lingkungan pengembangan berbasis Python dengan framework PyTorch sebagai pustaka utama untuk implementasi model pembelajaran mendalam.

Dataset Face Anti-Spoofing menggunakan LCC_FASD yang terdiri atas citra wajah asli (*realperson*) dan berbagai variasi serangan spoofing, seperti foto cetak, tampilan layar digital, topeng, manekin, dan jenis serangan lainnya. Seluruh kategori spoof digabungkan menjadi satu kelas **Spoof**, sedangkan citra wajah asli diberi label **Real**, sehingga proses klasifikasi dilakukan dalam bentuk klasifikasi biner.

Sementara itu, model Face Recognition menggunakan dataset VGGFace2 untuk menghasilkan representasi wajah berupa embedding berdimensi 512 menggunakan FaceNet (InceptionResnetV1). Kedua model kemudian diintegrasikan pada tahap inferensi sehingga proses verifikasi identitas hanya dilakukan terhadap wajah yang telah dinyatakan **Real** oleh model Face Anti-Spoofing.



Berdasarkan hasil evaluasi model face recognition, sistem memiliki 500 kelas identitas, ukuran input FaceNet 160×160 piksel, dan output embedding 512 dimensi. Model dilatih selama 50 epoch. Hasil evaluasi menunjukkan validation accuracy sebesar 96.29%, test accuracy sebesar 96.12%, dan test weighted F1-score sebesar 96.98%. Namun, test macro F1-score masih sebesar 43.88%. Hal ini menunjukkan bahwa performa model secara umum sudah baik, tetapi performa antar kelas belum sepenuhnya merata. Kemungkinan penyebabnya adalah distribusi dataset yang tidak seimbang.

5.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak

Keseluruhan proses pelatihan (*training*) dan pengujian (*testing*) model pada penelitian ini dieksekusi sepenuhnya menggunakan lingkungan komputasi berbasis pemroses sentral (*CPU-only*) ditenagai prosesor modern berarsitektur instruksi vektor tingkat tinggi dan kapasitas RAM minimal 16 GB guna menguji efektivitas optimasi *LightClassifier* serta efisiensi *cache embedding* biner tanpa bergantung pada akselerasi GPU. Di sisi perangkat lunak, ekosistem pengembangan dibangun di atas sistem operasi Microsoft Windows menggunakan bahasa pemrograman Python, dengan *framework* PyTorch Core sebagai penyusun arsitektur jaringan saraf dan manajemen *pipeline* data, serta Scikit-Learn untuk fungsionalitas pemisahan data terstratifikasi, pengodean label, dan kalkulasi metrik evaluasi akhir. Seluruh proses komputasi numerik dioptimalkan secara matematis menggunakan tipe data presisi campuran berbasis format bfloat16 (*Brain Floating Point*) yang didukung penuh oleh pustaka tingkat rendah Intel MKL (*Math Kernel Library*) guna mempercepat kalkulasi perkalian matriks pada arsitektur CPU modern secara signifikan dan mencegah hambatan *bottleneck* memori.

5.1.2 Karakteristik Dataset Uji

Keseluruhan proses pelatihan (*training*) dan pengujian (*testing*) model pada penelitian ini dieksekusi sepenuhnya menggunakan lingkungan komputasi berbasis pemroses sentral (*CPU-only*) ditenagai prosesor modern berarsitektur instruksi vektor tingkat tinggi dan kapasitas RAM minimal 16 GB guna menguji efektivitas optimasi *LightClassifier* serta efisiensi *cache embedding* biner tanpa bergantung pada akselerasi GPU. Di sisi perangkat lunak, ekosistem pengembangan dibangun di atas sistem operasi Microsoft Windows menggunakan bahasa pemrograman Python, dengan *framework* PyTorch Core sebagai

penyusun arsitektur jaringan saraf dan manajemen *pipeline* data, serta Scikit-Learn untuk fungsionalitas pemisahan data terstratifikasi, pengodean label, dan kalkulasi metrik evaluasi akhir. Seluruh proses komputasi numerik dioptimalkan secara matematis menggunakan tipe data presisi campuran berbasis format bfloat16 (*Brain Floating Point*) yang didukung penuh oleh pustaka tingkat rendah Intel MKL (*Math Kernel Library*) guna mempercepat kalkulasi perkalian matriks pada arsitektur CPU modern secara signifikan dan mencegah hambatan *bottleneck* memori.

5.2 Hasil Pengujian Model Face Recognition

Subbab ini menyajikan pemaparan komprehensif mengenai performa riil sistem pengenalan wajah (*Face Recognition*) secara kuantitatif berdasarkan data historis eksekusi eksperimen. Evaluasi dilakukan dengan menguji keandalan integrasi arsitektur FaceNet (InceptionResnetV1) yang dikombinasikan dengan blok klasifikasi dinamis *LightClassifier* pada data uji independen berskala besar guna mengukur kemampuan generalisasi parameter bobot jaringan saraf dalam memetakan identitas biometrik wajah secara presisi.

5.2.1 Analisis Metrik Kuantitatif

Pengujian performa kuantitatif pada tahapan evaluasi akhir model *Face Recognition* dirancang untuk mengukur keandalan sistem dalam mengenali identitas visual melalui serangkaian metrik standardisasi industri yang disajikan secara terperinci. Berdasarkan kalkulasi pengujian menggunakan total 98.822 sampel citra, model berhasil membukukan nilai akurasi pengujian (*Test Accuracy*) yang solid sebesar 96,12%, angka yang menunjukkan konsistensi tinggi apabila disandingkan dengan capaian akurasi validasi terbaiknya di level 96,30%. Validasi performa yang seimbang ini diperkuat oleh nilai rata-rata akurasi per kelas (*Mean Class Accuracy*) sebesar 96,18%, yang mengonfirmasi bahwa kemampuan model dalam mengenali karakteristik biometrik wajah terdistribusi secara merata di seluruh subfolder identitas tanpa mengalami penurunan performa ekstrem pada kelas-kelas tertentu. Selain itu, model mencatatkan nilai *Test F1-Score Weighted* yang sangat tinggi sebesar 96,98%, menandakan bahwa mayoritas sampel di dalam populasi data uji berhasil diklasifikasikan ke dalam label identitas yang tepat dengan tingkat presisi dan reliabilitas tinggi, walaupun nilai *Test F1-Score Macro* berada

pada angka 43,88% akibat adanya dampak dari fluktuasi distribusi atau kelangkaan jumlah sampel minor pada sebagian kecil folder identitas khusus.

Metrik Evaluasi	Nilai Capaian	Keterangan Kinerja Sistem
Test Accuracy	96,12%	Persentase total prediksi benar dari keseluruhan data uji
Mean Class Accuracy	96,18%	Rata-rata nilai akurasi dihitung secara mandiri per kelas
Test F1-Score Weighted	96,98%	Keseimbangan presisi dan sensitivitas berbasis bobot sampel
Test F1-Score Macro	43,88%	Rata-rata F1-score murni antar kelas tanpa pengaruh volume data

5.2.2 Analisis Kurva Pembelajaran (*Learning Curves*)

Analisis kurva pembelajaran sepanjang 50 *epoch* (123,7 menit pada CPU) menunjukkan penurunan *training loss* secara eksponensial di fase awal berkat optimalisasi penjadwalan OneCycleLR dengan *warmup* 30% yang mempercepat model melewati lokal minimum. Model berhasil mencapai titik konvergensi dengan *Best Validation Loss* sebesar 1,3230 dan mengunci puncak akurasi validasi pada angka 96,30%. Selisih *Overfitting Gap* yang sangat tipis (hanya 0,18%) terhadap akurasi pengujian akhir (96,12%) membuktikan secara empiris bahwa regulasi *Label Smoothing* ($\epsilon=0.1$) efektif menekan sifat *overconfidence* model, sehingga menghasilkan grafik pembelajaran yang stabil dan bebas dari gejala *overfitting* maupun *underfitting*.

5.2.3 Distribusi Akurasi per Kelas

Eksperimen sebaran tingkat keberhasilan identifikasi pada 500 kelas unik VGGFace2 membuktikan bahwa model bebas dari bias keputusan atau penurunan sensitivitas pada folder identitas tertentu. Melalui grafik distribusi, diketahui bahwa mayoritas mutlak akurasi individual kelas terkonsentrasi tinggi pada rentang 94% hingga 100%. Keberhasilan penyeragaman ini didorong oleh pemanfaatan teknik *Global Average Pooling* (GAP) yang mereduksi peta fitur spasial menjadi vektor *embedding* kompak sebelum dialirkan ke *LightClassifier*, sehingga model tetap tangguh terhadap variasi ekspresi, rotasi sudut pandang (*head pose*), maupun pencahayaan, serta memiliki kemampuan generalisasi yang merata.

5.3 Hasil Pengujian Model Anti-Spoofing

Evaluasi Face Anti-Spoofing dilakukan untuk mengukur kemampuan model dalam membedakan wajah asli dengan berbagai bentuk media pemalsuan. Berbeda dengan sistem klasifikasi konvensional yang hanya menggunakan nilai akurasi, evaluasi pada sistem anti-spoofing menggunakan metrik yang telah menjadi standar pada pengujian biometrik, yaitu Attack Presentation Classification Error Rate (APCER), Bona Fide Presentation Classification Error Rate (BPCER), dan Average Classification Error Rate (ACER).

Nilai APCER menunjukkan persentase serangan spoofing yang masih berhasil lolos sebagai wajah asli. Semakin kecil nilai APCER, semakin baik kemampuan sistem dalam mendeteksi media pemalsuan.

Nilai BPCER menunjukkan persentase wajah asli yang salah diklasifikasikan sebagai spoof. Nilai yang rendah menunjukkan bahwa sistem mampu menerima pengguna yang sah tanpa menghasilkan penolakan yang berlebihan.

Nilai ACER merupakan rata-rata antara APCER dan BPCER sehingga digunakan sebagai indikator performa keseluruhan model. Semakin kecil nilai ACER, semakin baik keseimbangan antara keamanan sistem dan kenyamanan pengguna.

Hasil pengujian menunjukkan bahwa pendekatan *weighted ensemble* menghasilkan performa yang lebih stabil dibandingkan penggunaan satu model tunggal. Setiap model memiliki karakteristik yang berbeda dalam mengenali tekstur dan pola visual pada media spoofing sehingga kombinasi beberapa model mampu meningkatkan kemampuan generalisasi sistem terhadap berbagai variasi serangan.

5.3.1 Analisis Weighted Ensemble

Pendekatan *weighted ensemble* mengombinasikan beberapa model Face Anti-Spoofing yang bekerja secara independen terhadap citra masukan. Setiap model menghasilkan probabilitas terhadap kelas Real maupun Spoof, kemudian seluruh probabilitas tersebut digabungkan menggunakan bobot tertentu sehingga menghasilkan keputusan akhir.

Penggunaan beberapa model secara bersamaan bertujuan untuk memanfaatkan keunggulan masing-masing arsitektur dalam mempelajari karakteristik visual yang berbeda. Model tertentu memiliki kemampuan lebih baik dalam mengenali tekstur permukaan wajah, sedangkan model lainnya lebih sensitif terhadap pola pencahayaan maupun distribusi warna. Dengan menggabungkan seluruh informasi tersebut, sistem mampu menghasilkan prediksi yang lebih stabil dibandingkan penggunaan satu model saja.

Selain meningkatkan akurasi klasifikasi, pendekatan ensemble juga mampu mengurangi variasi prediksi yang disebabkan oleh karakteristik dataset tertentu sehingga performa sistem menjadi lebih konsisten ketika digunakan pada lingkungan operasional.

5.4 Analisis Kebingungan Model (*Confusion Matrix Analysis*)

Subbab ini menyajikan pembahasan mendalam mengenai kegagalan atau kesalahan klasifikasi (*misclassification*) yang masih terjadi pada sistem melalui visualisasi matriks kebingungan (*confusion matrix*). Analisis ini sangat penting untuk mengidentifikasi batas kemampuan model (*model boundary limits*) baik dalam mengenali identitas wajah berskala besar maupun dalam mendeteksi variasi serangan tiruan, sehingga dapat ditarik kesimpulan ilmiah mengenai faktor-faktor visual dan tekstural yang melandasi terjadinya ambiguitas prediksi.

5.4.1 Matriks Kebingungan Multi-Kelas (Wajah)

Investigasi matriks kebingungan multi-kelas pada model *Face Recognition* menunjukkan bahwa kesalahan klasifikasi minor yang tersisa murni disebabkan oleh kemiripan visual (*visual similarity*) ekstrem antar-individu, seperti kesamaan geometri tulang wajah, bentuk rahang, atau kedekatan ras. Faktor eksternal berupa oklusi parsial (kacamata atau poni), sudut kemiringan wajah (*head pose*) ekstrem, serta distorsi pencahayaan yang mereduksi ketegasan garis biometrik turut memicu bergesernya koordinat vektor *embedding* wajah ke dalam radius keputusan (*decision boundary*) milik kelas identitas lain yang salah. Walaupun demikian, secara keseluruhan model tetap mampu memetakan 500 kelas identitas VGGFace2 dengan tingkat akurasi diagonal yang sangat solid.

5.5 Integrasi Face Anti-Spoofing dan Face Recognition

Tahap integrasi dilakukan dengan menghubungkan model Face Anti-Spoofing dan Face Recognition dalam satu pipeline inferensi. Setiap citra yang diterima sistem terlebih dahulu diproses oleh model Face Anti-Spoofing. Hanya citra yang diklasifikasikan sebagai **Real** yang diteruskan menuju proses ekstraksi *embedding* menggunakan FaceNet.

Pendekatan ini memberikan lapisan keamanan tambahan dibandingkan sistem Face Recognition konvensional. Identitas pengguna tidak akan diverifikasi apabila citra yang digunakan terindikasi berasal dari media pemalsuan, sehingga peluang terjadinya *presentation attack* dapat dikurangi secara signifikan.

Integrasi kedua model menghasilkan sistem autentikasi biometrik yang tidak hanya mampu mengenali identitas pengguna secara akurat, tetapi juga memastikan bahwa proses autentikasi dilakukan menggunakan wajah asli yang hadir secara langsung di depan kamera.

BAB VI

KESIMPULAN

6.1 Kesimpulan

Berdasarkan seluruh rangkaian tahapan eksperimen, analisis hasil, dan pengujian sistem komplementer pengenalan wajah yang telah dilaksanakan, maka dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Integrasi arsitektur FaceNet (InceptionResnetV1) dengan modul klasifikasi dinamis LightClassifier terbukti mampu melakukan pengenalan wajah multi-kelas secara efektif. Model memperoleh Test Accuracy sebesar 96,12% dan Mean Class Accuracy sebesar 96,18% pada 98.822 sampel uji yang terdiri atas 500 kelas identitas dari dataset VGGFace2. Selain itu, model menghasilkan Weighted F1-Score sebesar 96,98%, yang menunjukkan performa klasifikasi secara keseluruhan sangat baik. Sementara itu, nilai Macro F1-Score sebesar 43,88% mengindikasikan masih adanya ketidakseimbangan distribusi data pada beberapa kelas dengan jumlah sampel yang relatif sedikit.
2. Model Face Anti-Spoofing berbasis weighted ensemble berhasil meningkatkan keamanan sistem absensi dengan mendeteksi dan membedakan wajah asli (*real*) dari berbagai bentuk media pemalsuan (*spoof*). Pendekatan ini mengombinasikan beberapa model, yaitu MiniFASNet (SASF), FLRGB, ICM2O, IOM2C, dan CDCN++, sehingga menghasilkan keputusan klasifikasi yang lebih stabil dibandingkan penggunaan model tunggal. Berdasarkan hasil pengujian menggunakan metrik Attack Presentation Classification Error Rate (APCER), Bona Fide Presentation Classification Error Rate (BPCER), dan Average Classification Error Rate (ACER), model menunjukkan kemampuan yang baik dalam mendeteksi serangan *presentation attack* sekaligus mempertahankan tingkat penerimaan terhadap wajah asli. Integrasi model Face Anti-Spoofing sebagai tahap awal sebelum proses Face Recognition berhasil meningkatkan keamanan sistem dengan mencegah penggunaan foto, tampilan layar, maupun media pemalsuan lainnya pada proses absensi.
3. Penerapan berbagai teknik optimasi pada lingkungan CPU-only, seperti pre-computing FaceNet embeddings menggunakan penyimpanan berkas *.npz*, penggunaan presisi campuran bfloat16, Label Smoothing ($\epsilon=0,1$), dan MixUp ($\alpha=0,3$), terbukti mampu meningkatkan efisiensi pelatihan sekaligus menjaga kemampuan generalisasi model. Seluruh proses pelatihan berlangsung selama 123,7 menit dengan mekanisme early stopping pada epoch ke-43 dari maksimum 50 epoch. Selain itu, selisih antara akurasi validasi terbaik dan akurasi pengujian akhir hanya sebesar 0,18%, yang menunjukkan bahwa model mengalami overfitting dalam tingkat yang sangat rendah.

4. Mekanisme verifikasi wajah berlapis yang mengkombinasikan Cosine Similarity dengan skor Anti-Spoofing melalui persamaan:

$$[\text{final_score}] = (0,7 \times \text{similarity}) + (0,3 \times \text{spoof_score})$$

terbukti mampu meningkatkan keandalan proses autentikasi. Dengan menerapkan ambang keputusan $\text{similarity} \geq 0,75$, $\text{spoof score} \geq 0,85$, dan $\text{final score} \geq 0,80$, sistem mampu meminimalkan kemungkinan False Acceptance Rate (FAR) serta berhasil mendeteksi berbagai bentuk serangan spoofing, seperti penggunaan layar digital (*fake screen*) maupun topeng (*fake mask*). Hasil tersebut menunjukkan bahwa kombinasi pengenalan identitas dan deteksi liveness mampu meningkatkan keamanan sistem secara keseluruhan.

6.2 Saran

Pengembangan selanjutnya dapat difokuskan pada peningkatan kualitas dan keseimbangan dataset agar nilai macro F1-score meningkat. Selain itu, sistem perlu diuji pada kondisi nyata dengan variasi pencahayaan, kualitas kamera, pose wajah, dan kondisi operasional hotel. Pengembangan berikutnya juga dapat menambahkan challenge-response liveness seperti kedip mata, menoleh ke kiri/kanan, tersenyum, atau membuka mulut untuk meningkatkan keamanan terhadap spoofing.

Daftar Pustaka

- [1] F. Schroff, D. Kalenichenko, and J. Philbin, “FaceNet: A Unified Embedding for Face Recognition and Clustering,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.
- [2] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, “Joint Face Detection and Alignment using Multi-task Cascaded Convolutional Networks,” *IEEE Signal Processing Letters*, 2016.
- [3] Q. Cao, L. Shen, W. Xie, O. M. Parkhi, and A. Zisserman, “VGGFace2: A Dataset for Recognising Faces across Pose and Age,” *IEEE International Conference on Automatic Face & Gesture Recognition (FG)*, 2018.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [5] Z. Yu, X. Li, P. Wang, and G. Zhao, “Deep Learning for Face Anti-Spoofing: A Survey,” *arXiv preprint arXiv:2106.14948*, 2021.
- [6] Y. Liu, J. Stehouwer, A. Jourabloo, and X. Liu, “Deep Tree Learning for Zero-Shot Face Anti-Spoofing,” *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [7] Z. Ming, M. Visani, M. M. Luqman, and J.-C. Burie, “A Survey on Anti-Spoofing Methods for Face Recognition with RGB Cameras of Generic Consumer Devices,” *arXiv preprint arXiv:2010.04145*, 2020.
- [8] T. Esler, “facenet-pytorch: Pretrained Pytorch Face Detection and Recognition Models,” GitHub Repository, 2019.
- [9] OpenCV, “Canny Edge Detection,” *OpenCV-Python Tutorials*.
- [10] OpenCV, “Hough Line Transform,” *OpenCV-Python Tutorials*.
- [11] scikit-learn Developers, “scikit-learn: Machine Learning in Python,” *scikit-learn Documentation*.